

Endüstri 4.0 Uygulamalarında Tahminci Bakım İçin Dengesiz Veri Setlerinde Makine Öğrenmesi Algoritmalarının Bütüncül Performans Analizi

Beyzanur BAŞARAN^{1*}, Güzide KAYA¹, İkbâl GÖKÇE¹, Mahmut Esat KOLAY¹,
Emre Yaşar ÇİFTÇİ¹, Osman Melih KOCAOĞLU¹

¹ Department of Computer Engineering, Selçuk University Faculty of Technology, Selçuklu, Konya

(beyzanurbasaran710@gmail.com ; guzidekaya7@gmail.com ; ikbalgokce41@gmail.com ; esat.kolay19@gmail.com ;
emreciftci8@gmail.com ; o.melihkocaoglu@gmail.com)

*(beyzanurbasaran710@gmail.com)

Özet - Endüstri 4.0 paradigması ile birlikte üretim hatlarının dijitalleşmesi, makinelerin sağlık durumunun izlenmesini ve olası arızaların önceden tespit edilmesini sağlayan kestirimci bakım uygulamalarını kritik hale getirmiştir. Bu çalışmada, endüstriyel bir frezeleme tezgahını simüle eden AI4I 2020 veri seti kullanılarak makine arızalarının tahmin edilmesi hedeflenmiştir. Literatürdeki birçok çalışmanın aksine, bu araştırmada sınıf dengesizliğinin yarattığı değerlendirme yanılgılarını gidermek amacıyla bütüncül bir performans analizi benimsenmiştir. Çalışma kapsamında; Lojistik Regresyon, Destek Vektör Makineleri, Karar Ağacı ve Rastgele Orman olmak üzere dört farklı makine öğrenmesi algoritmasının performansı karşılaştırılmıştır. Veri setinde bulunan ciddi sınıf dengesizliği (%96,6 Çalışır, %3,4 Arızalı) nedeniyle, modellerin başarısı sadece Doğruluk (Accuracy) metriği ile değil; Duyarlılık (Recall), F1-Skoru ve ROC-AUC gibi ayırt edici metrikler üzerinden analiz edilmiştir. Deneysel sonuçlar, tüm algoritmaların %97'nin üzerinde genel doğruluk oranına ulaştığını; ancak doğrusal modellerin (Lojistik Regresyon) arıza tespitinde (Recall: 0,14) yetersiz kaldığını göstermiştir. Buna karşın, topluluk öğrenme (ensemble learning) temelli Rastgele Orman algoritması, %98,29 doğruluk oranı ve 0,97 ROC-AUC değeri ile hem genel başarıda hem de nadir görülen arızaları tespit etme konusunda en üstün performansı sergilemiştir. Çalışma, dengesiz veri setlerine sahip endüstriyel bakım problemlerinde, model seçiminin ve doğru performans metriklerinin kullanılmasının önemini deneysel olarak ortaya koymaktadır.

Anahtar Kelimeler – Kestirimci Bakım, Makine Öğrenmesi, Dengesiz Veri Seti, Rastgele Orman, Endüstri 4.0.

GİRİŞ

Endüstri 4.0, üretim süreçlerinin dijitalleşmesi, siber-fiziksel sistemlerin (Cyber-Physical Systems - CPS) fabrikalara entegrasyonu ve Nesnelerin İnterneti (Internet of Things - IoT) teknolojilerinin yaygınlaşması ile karakterize edilen yeni bir sanayi devrimini temsil etmektedir [1]. Bu paradigma, endüstriyel cihazların ve sensörlerin birbirleriyle otonom olarak iletişim kurabildiği "akıllı fabrikaların" oluşumuna zemin hazırlamıştır. Ancak bu akıllı sistemlerin sürdürülebilirliği, üretim verimliliğini doğrudan etkileyen bakım stratejilerine bağlıdır. Endüstriyel üretimde makinelerin beklenmedik şekilde arızalanması, işletmeler için hem maliyet hem de operasyonel süreklilik açısından kritik bir sorundur. Yapılan çalışmalar, plansız makine duruşlarının toplam üretim kapasitesini %5–20 oranında düşürdüğünü, bakım maliyetlerini ise %30'a varan oranlarda artırdığını göstermektedir [2]. Özellikle otomotiv gibi yüksek hacimli üretim yapan sektörlerde, plansız makine duruşlarının işletmelere maliyeti saatlik 2 milyon ABD doları (United States Dollar – USD) seviyesine ulaşmaktadır [3].

Bu ekonomik kayıpları önlemek amacıyla, geleneksel "Reaktif Bakım" (Reactive Maintenance) ve "Önleyici Bakım" (Preventive Maintenance) yaklaşımları yerini giderek veri odaklı "Kestirimci Bakım" (Predictive Maintenance - PdM) yaklaşımına bırakmaktadır. Kestirimci bakım, makinelerin sağlık durumunu izleyerek potansiyel arızaları henüz gerçekleşmeden tespit etmeyi ve Kalan Faydalı Ömrü (Remaining Useful Life - RUL) öngörmeyi hedefler [4]. Makine arızaları genel olarak aşırı takım aşınması, yetersiz ısı transferi, güç dengesizliği ve mekanik zorlanma gibi kategorilere ayrılmaktadır [5]. Bu arıza modları, sensör verilerindeki değişimlerle yakından ilişkilidir. Örneğin; takım aşınması çoğunlukla kesme kuvveti ve diğer mekanik sensör sinyallerinde düzensiz dalgalanmalarla kendini gösterirken, proses sırasında oluşan ısı etkileri sıcaklıkla ilişkili ölçümlerdeki değişimlere yansıtılabilmektedir. Literatürde, kesme kuvveti, titreşim, akustik emisyon ve sıcaklık gibi çoklu sensör

kaynaklarından elde edilen verilerin birlikte değerlendirilmesinin, takım durumu ve makine sağlığının izlenmesinde en güvenilir yaklaşımlardan biri olduğu belirtilmektedir [6].

Bu karmaşık sensör verilerinin işlenmesi ve anlamlandırılması sürecinde makine öğrenmesi algoritmaları kilit bir rol oynamaktadır. Literatürde, kestirimci bakım modellerinin başarısını artırmak için farklı matematiksel temellere dayanan algoritmalar kullanılmaktadır [7]. Bunlar arasında; olasılıksal bir temel sunan Lojistik Regresyon (Logistic Regression - LR), veriyi çok boyutlu uzayda ayırarak sınıflandıran Destek Vektör Makineleri (Support Vector Machines - SVM), kural tabanlı yapısıyla şeffaflık sağlayan Karar Ağaçları (Decision Trees - DT) ve topluluk öğrenmesi (ensemble learning) gücüyle yüksek genelleme başarısı sunan Rastgele Orman (Random Forest - RF) yöntemleri öne çıkmaktadır [8]. Ancak literatürdeki tartışmaların çoğu, hangi yaklaşımın (basit doğrusal modeller mi yoksa karmaşık topluluk modelleri mi) gürültülü ve dengesiz endüstriyel verilerde daha başarılı olduğu üzerinedir [9].

İlgili Çalışmalar ve Literatürdeki Yeri

PdM alanında makine öğrenmesi algoritmalarının kullanımı üzerine literatürde kapsamlı çalışmalar bulunmakla birlikte; bu çalışmalar model karmaşıklığı, veri işleme stratejileri ve optimizasyon hedefleri açısından önemli farklılıklar göstermektedir. Mevcut literatür incelendiğinde, çalışmaların genellikle belirli bir kısıt veya odak noktası etrafında şekillendiği görülmektedir. Örneğin, kullanılan veri setinin oluşturucusu olan Matzka [5], çalışmada Açıklanabilir Yapay Zeka (Explainable AI - XAI) kavramına odaklanarak modellerin karar mekanizmalarını görselleştirmeyi hedeflemiş, ancak sınıf dengesizliğinin arıza yakalama (Recall) performansı üzerindeki negatif etkilerini derinlemesine analiz etmemiştir. Bu çalışmada ise DT ile açıklanabilirlik korunurken, RF algoritması ile arıza tespit başarısının maksimize edilmesi hedeflenerek, literatürdeki bu boşluğun doldurulması amaçlanmıştır.

Model mimarisi ve uygulanabilirlik açısından değerlendirildiğinde, Zhao ve ark. [10] gibi araştırmacıların Derin Öğrenme (Deep Learning - DL) tabanlı Uzun Kısa Süreli Bellek (Long Short-Term Memory - LSTM) ve Evrişimli Sinir Ağları (Convolutional Neural Networks - CNN) gibi karmaşık modeller önerdiği görülmektedir. Bu modeller yüksek başarı oranları sunsa da gerektirdikleri yüksek işlem gücü ve "Kara Kutu" (Black Box) yapıları nedeniyle, özellikle uç (edge) cihazlarda ve gerçek zamanlı endüstriyel uygulamalarda entegrasyon zorlukları yaratmaktadır. Bu çalışmada, karmaşık DL mimarileri yerine, daha az kaynak tüketen, hızlı ve endüstriyel sistemlere entegrasyonu kolay olan temel makine öğrenmesi algoritmaları (RF, SVM) tercih edilerek, uygulanabilirlik açısından bir avantaj sağlanmıştır.

Öte yandan, problemin ele alınış biçimi ve hedef fonksiyonları açısından da farklı yaklaşımlar mevcuttur. Rizzi ve ark. [11], problemi bir maliyet optimizasyonu olarak kurgulamış ve yanlış sınıflandırmaların ekonomik bedelini minimize eden "Maliyet Duyarlı" (Cost-Sensitive) yöntemler geliştirmiştir. Ancak maliyet parametrelerinin endüstriden endüstriye ve işletmeden işletmeye değişkenlik göstermesi, bu modellerin genellenebilirliğini kısıtlamaktadır. Bu çalışma, değişken ekonomik parametrelerden bağımsız olarak, algoritmaların teknik arıza tespit yeteneğine (detection capability) odaklanması ve "Güvenlik Kritik" (safety-critical) kararlar için saf performansı ölçmesiyle söz konusu çalışmalardan ayrılmaktadır.

Son olarak, veri bütünlüğü ve metodolojik yaklaşım açısından bu çalışma, literatürdeki yaygın uygulamalardan (Susto [4], Carvalho [2]) farklı bir yol izlemektedir. Birçok çalışmada sınıf dengesizliğini gidermek için Sentetik Azınlık Aşırı Örnekleme Tekniği (Synthetic Minority Over-sampling Technique - SMOTE) gibi sentetik veri çoğaltma tekniklerine başvurulurken, bu çalışmada algoritmaların doğal ve dengesiz koşullar altındaki performansı test edilmiştir. Ayrıca, Kaufman [12] tarafından "veri sızıntısı" (data leakage) olarak tanımlanan ve literatürde hatalı yüksek başarı oranlarına neden olan Takım Aşınma Arızası (Tool Wear Failure - TWF) ve Isı Dağılımı Arızası (Heat Dissipation Failure - HDF) gibi arıza türü etiketleri eğitim setinden çıkarılarak, sonuçların gerçekçi, güvenilir ve saha koşullarına uygun olması sağlanmıştır.

Bu bağlamda çalışma, literatürde belirtilen veri dengesizliği sorunlarını ele almak ve dört farklı algoritma sınıfının performansını kıyaslamak amacıyla kurgulanmıştır. Çalışmada, gerçek dünya sensör verilerini simüle eden AI4I 2020 Predictive Maintenance Dataset kullanılmıştır [5]. Araştırma kapsamında; olasılıksal temelli LR, marjin tabanlı SVM, kural tabanlı DT ve topluluk öğrenme temelli RF algoritmaları ele alınmıştır. Modellerin performansları, dengesiz veri setlerinde sadece Doğruluk (Accuracy) metriğinin yanıltıcı olabileceği göz önünde bulundurularak; Kesinlik (Precision), Duyarlılık (Recall), F1-Skoru (F1-Score) ve Alıcı İşletim Karakteristiği - Eğri Altında Kalan Alan (Receiver Operating Characteristic - Area Under Curve - ROC-AUC) gibi ayırt edici metrikler üzerinden bütüncül olarak analiz edilmiştir. Bu çalışmanın temel amacı, Endüstri 4.0 tabanlı PdM sistemlerinde; doğrusal ve

doğrusal olmayan sınıflandırma yöntemlerinin özellikle arızaları tespit etme (Recall) başarısındaki farklarını deneysel olarak ortaya koymaktır.


MATERYAL VE METOD

Bu çalışmada, Endüstri 4.0 tabanlı PdM sistemlerinde kritik bir öneme sahip olan makine arıza tahmini (machine failure prediction) problemi ele alınmıştır. Çalışmanın temel amacı; endüstriyel verilerin doğasında bulunan "dengesiz veri" (imbalanced data) problemini yönetmek ve bu zorlu koşul altında, literatürde yaygın olarak kullanılan sınıflandırma algoritmalarının performanslarını karşılaştırmalı olarak analiz etmektir.

Bu kapsamda; LR, SVM, DT ve RF makine öğrenmesi yaklaşımlarının, arıza tespitindeki başarımları kıyaslanmıştır. Çalışma metodolojisi; veri setinin özelliklerinin istatistiksel analizi, veri sızıntısını (data leakage) önleyici ön işleme adımları, algoritmaların yapılandırılması ve 10-katlı çapraz doğrulama (10-Fold Cross-Validation) ile performansın ölçülmesi aşamalarından oluşmaktadır. Tüm deneysel çalışmalar Python programlama dili ve Scikit-learn kütüphanesi kullanılarak gerçekleştirilmiştir.

Veri Seti Özellikleri


Bu çalışma kapsamında, endüstriyel bakım uygulamalarında sıkça referans alınan ve gerçek bir Bilgisayarlı Sayısal Kontrol (Computer Numerical Control - CNC) frezeleme tezgahının operasyonel süreçlerini simüle eden AI4I 2020 Predictive Maintenance Dataset kullanılmıştır [5]. UCI Makine Öğrenmesi Veri Tabanı (UCI Machine Learning Repository) üzerinden temin edilen veri seti, makinenin anlık sağlık durumunu karakterize eden 10.000 adet gözlemden oluşmaktadır. Her bir örneklem; Hava Sıcaklığı (K), Proses Sıcaklığı (K), Dönüş Hızı (rpm), Tork (Nm) ve Alet Aşınma Süresi (min) gibi fiziksel sensör verilerini içermektedir. Sensör verilerinin dağılımları ve istatistiksel karakteristikleri, veri ön işleme ve aykırı değer tespiti süreçleri kapsamında incelenmiş olup, temel özniteliklere ait dağılım grafikleri Şekil 1’de sunulmuştur.



Şekil 1. Sensör verilerinin istatistiksel dağılımı ve yoğunluk eğrileri.

Söz konusu veri setini literatürdeki diğer sentetik veri setlerinden ayıran en belirgin özellik, hedef değişken olan "Makine Arızası" (Machine Failure) etiketinin rastgele stokastik süreçlere değil, deterministik fiziksel süreçlere dayanmasıdır. Çalışmada ele alınan ikili sınıflandırma (binary classification) problemi, esasen beş farklı kök nedenin bileşiminden meydana gelmektedir. Bu arıza modları; takımın kullanım ömrünü tamamlamasıyla ilişkili TWF, soğutma yetersizliğinden kaynaklanan HDF, güvenli çalışma aralığının aşılmasıyla tetiklenen Güç Arızası (Power Failure - PWF), tork yükünün kritik eşiği aşması sonucu oluşan Aşırı Zorlanma Arızası (Overstrain Failure - OSF) ve sistemik belirsizliklere dayalı Rastgele Arızalar (Random Failures - RNF) olarak tanımlanmıştır. Çalışmanın temel amacı, bu beş arıza modundan herhangi birinin gerçekleşmesi durumunda, algoritmaların makineyi "Arızalı" olarak tanımlama başarısını analiz etmektir.

Veri setinin sınıf dağılımı analiz edildiğinde, endüstriyel bakım verilerinin doğasıyla uyumlu olarak ciddi bir sınıf dengesizliği (class imbalance) göze çarpmaktadır. Şekil 2'de görselleştirildiği üzere, toplam verinin 9.661 adedi (%96,6) "Çalışır" (Sınıf 0) durumunu temsil ederken, "Arızalı" (Sınıf 1) durumu yalnızca 339 adet (%3,4) gözlemden oluşmaktadır. Bu yapı, modellerin eğitim sürecinde çoğunluk sınıfına yönelik yanlılık (bias) geliştirme riskini barındırmakla birlikte, çalışmanın gerçek dünya senaryolarına olan uygunluğunu artırmaktadır.



Şekil 2. Veri setindeki sınıf dengesizliği (Çalışır vs. Arızalı).

Sınıf dengesizliğinin yol açtığı metodolojik kısıtlar literatürde geniş yer bulmaktadır. Özellikle Carvalho ve arkadaşları (2019) [2], PdM algoritmaları üzerine gerçekleştirdikleri sistematik literatür taramasında, çalışmaların büyük çoğunluğunun yalnızca Accuracy metriğine odaklandığını; ancak dengesiz veri setlerinde bu yaklaşımın, algoritmaların sadece çoğunluk sınıfını tahmin ederek yapay bir başarı sergilemesine ve asıl kritik olan arızaları gözden kaçırmaya yol açtığını raporlamışlardır.

Bu tespitten hareketle, mevcut çalışmanın literatürdeki benzerlerinden ayrıştığı temel nokta; [2] numaralı çalışmada vurgulanan değerlendirme yanlılıklarını (evaluation bias) elimine eden bütüncül bir performans analizi benimsemesidir. Bu bağlamda, dengesiz veri setlerinde yanıltıcı sonuçlar verebilen genel Accuracy metriği yerine, algoritmaların nadir görülen arıza durumlarını tespit etme kapasitesini ölçen Recall ve ROC-AUC metrikleri önceliklendirilmiştir.

Veri Ön İşleme Adımları

Ham verilerin makine öğrenmesi algoritmaları tarafından doğru yorumlanabilmesi ve modellerin yakınsama hızının artırılması amacıyla, eğitim öncesinde bir dizi ön işleme adımı uygulanmıştır:

İlk olarak, modelin öğrenme sürecine katkı sağlamayan ve sadece tanımlayıcı nitelik taşıyan Tekil Kimlik (UID) ve Ürün Kodu (Product ID) sütunları veri setinden çıkarılarak gürültü oluşumu engellenmiştir.

İkinci aşamada, makine öğrenmesi modellerinin matematiksel vektör uzayında çalışması gerekliliği nedeniyle, kategorik bir değişken olan Ürün Kalitesi (Type: L, M, H) özniteliği, Kodlama (Encoding) işlemi ile sayısal değerlere dönüştürülmüştür.

Üçüncü ve en kritik aşama ise öznitelik ölçeklendirmesidir (Feature Scaling). Veri setindeki sensör verileri incelendiğinde (Şekil 1); dönüş hızı değerlerinin binli basamaklarda (1500-2800 rpm), sıcaklık değerlerinin ise yüzölçü basamaklarda (295-305 K) olduğu görülmüştür. Değer aralıkları arasındaki bu büyük varyasyon, özellikle Öklid mesafesi (Euclidean distance) temelinde çalışan algoritmaların (SVM gibi) hatalı ağırlıklandırma yapmasına neden olabilmektedir. Bu sorunu gidermek amacıyla, tüm sürekli değişkenler ortalaması 0 ve standart sapması 1 olacak şekilde Standardizasyon (Standard Scaler) işlemine tabi tutulmuştur.

Son aşamada ise; veri setindeki yüksek dengesizlik oranı nedeniyle, statik bir eğitim-test ayrımı (örneğin %70-%30) yapmanın modelin azınlık sınıfını öğrenme yeteneğini doğru yansıtmayacağı değerlendirilmiştir. Bu nedenle, modelin genelleme başarısını daha objektif ve güvenilir bir şekilde ölçmek adına 10-katlı çapraz doğrulama yöntemi uygulanmıştır.

Uygulanan Algoritmalar

Endüstriyel arıza tespiti probleminin çözümü için, farklı matematiksel temellere dayanan dört denetimli öğrenme algoritmasının performansı kıyaslanmıştır:

Lojistik Regresyon (LR): Bu çalışmada, sensör verileri ile arıza olasılığı arasındaki ilişkinin doğrusal olup olmadığını test etmek amacıyla temel referans (baseline) model olarak seçilmiştir. LR, bağımsız değişkenlerin ağırlıklı toplamını Sigmoid fonksiyonundan geçirerek, makinenin arızalanma olasılığını 0 ile 1 arasında bir değer olarak tahmin eder [13]. Özellikle işlem yükünün düşük olması ve sonuçların yorumlanabilirliği açısından endüstride tercih edilse de, karmaşık ve doğrusal olmayan arıza paternlerinde yetersiz kalabilmektedir.


Destek Vektör Makineleri (SVM): Veri setindeki "Sağlam" ve "Arızalı" sınıflarını birbirinden en iyi ayıran hiper düzlemi (hyperplane) bulmak amacıyla kullanılmıştır. SVM, sınıflar arasındaki marjini maksimize ederek modelin genelleme yeteneğini artırmayı hedefler [14]. Bu çalışmada SVM'in tercih edilme nedeni, yüksek boyutlu sensör verilerini çekirdek (kernel) fonksiyonları aracılığıyla daha yüksek boyutlu bir uzaya taşıyarak, doğrusal olmayan arıza ilişkilerini çözme potansiyelidir. Ancak, eldeki veri setinin boyutu ve dengesizliği göz önüne alındığında, eğitim süresinin uzunluğu ve duyarlılık performansı kritik bir değerlendirme parametresi olacaktır.

Karar Ağaçları (DT): Sensör verilerini belirli eşik değerlere göre (Örneğin: "Sıcaklık > 310 K ise...") hiyerarşik olarak bölerek sonuca ulaşan kural tabanlı bir yöntemdir [15]. Çalışmada kullanılmasının temel nedeni, modelin oluşturduğu "Eğer-O Halde" kurallarının mühendisler tarafından kolayca anlaşılabilir olmasıdır (white-box model). DT, veri dağılımındaki ölçek farklarından etkilenmese de, eğitim verisine aşırı uyum sağlama (overfitting) riski taşıdığı için budama (pruning) ve hiperparametre optimizasyonu gerektirebilmektedir.

Rastgele Orman (RF): DT'nin aşırı öğrenme problemini aşmak ve dengesiz veri setlerinde daha kararlı sonuçlar elde etmek amacıyla kullanılan bir topluluk (ensemble) öğrenme yöntemidir [8]. "Bagging" tekniği ile yüzlerce farklı karar ağacını eğitir ve çoğunluk oylaması ile nihai kararı verir. Bu çalışmada RF algoritmasının, içerdiği çoklu karar mekanizması sayesinde gürültülü sensör verilerini daha iyi tolere etmesi ve nadir görülen arıza durumlarını (Recall) tespit etmede tekil modellere göre daha üstün bir performans gösterebileceği beklenmektedir.

DeneySEL Sonuçların Değerlendirilmesi

Modellerin performansı, 10-katlı çapraz doğrulama yöntemi ile test edilmiştir. Şekil 3'te görüldüğü üzere, algoritmaların doğruluk (Accuracy) oranları birbirine yakın (LR %97,01; RF %98,29) görünmektedir.



Şekil 3. Algoritmaların 10-katlı çapraz doğrulama doğruluk ve varyans dağılımları.


Model başarısı değerlendirilirken, dengesiz veri setinin yarattığı "Doğruluk Paradoksu"nu (accuracy paradox) aşmak için sadece Accuracy metriği yeterli görülmemiştir. Bu nedenle analizlerde; yanlış alarmları ölçen Precision, arızaları kaçırma oranını gösteren Recall, bu ikisinin harmonik ortalaması olan F1-Score ve modelin ayırt etme gücünü gösteren ROC-AUC eğrisi temel alınmıştır.

BULGULAR VE TARTIŞMA

Bu bölümde, Endüstri 4.0 tabanlı kestirimci bakım senaryosu için geliştirilen LR, SVM, DT ve RF modellerinin performans sonuçları sunulmuş ve detaylı olarak tartışılmıştır. Modellerin başarısı; veri setindeki dengesiz dağılımın modeller üzerindeki etkisi gözetilerek, sadece Accuracy metriği ile değil; arıza tespit yeteneğini gösteren Precision, Recall, F1-Score ve modelin ayırt etme gücünü ifade eden ROC-AUC değerleri üzerinden bütüncül olarak analiz edilmiştir.

Genel Performans Karşılaştırması

Modellerin test seti üzerindeki genel Accuracy oranları incelendiğinde (Şekil 4), tüm algoritmaların %97'nin üzerinde bir başarı sergilediği görülmektedir. RF algoritması %98,23 ile en yüksek doğruluğa ulaşırken, LR %97,01 ile en düşük performansı göstermiştir. Ancak aradaki farkın sadece %1,22 olması, ilk bakışta tüm modellerin benzer performans gösterdiği izlenimini yaratmaktadır.




Şekil 4. Modellerin test seti üzerindeki genel doğruluk (Accuracy) oranları.

Bu yüksek Accuracy oranları, literatürde "Doğruluk Paradoksu" (accuracy paradox) olarak adlandırılan yanılgının tipik bir örneğidir. Veri setinin %96,6'sının "Çalışır" olduğu bir senaryoda, bir model hiç öğrenme gerçekleştirmeden tüm verileri "Çalışır" olarak tahmin etse dahi %96,6 taban başarı oranına ulaşacaktır. Bu nedenle, modellerin gerçek endüstriyel başarısını görmek için sınıf bazlı ayrımların yapıldığı Karmaşıklık Matrisleri (Confusion Matrix) incelenmelidir.

Karmaşıklık Matrisi Analizi ve Arıza Tespit Başarısı


PdM uygulamalarında model başarısını değerlendirirken en kritik husus, arızalı bir makinenin "Çalışır" olarak tahmin edilmesidir (False Negative - FN). Bu tür bir hata, arızanın öngörülememesine, plansız duruşlara ve yüksek maliyetlere yol açacağı için kabul edilemezdir. Bu nedenle modellerin sadece genel Accuracy performansına değil, sınıfları ne kadar doğru ayırdığına bakmak gerekir. Şekil 5 ve Şekil 6'da çalışmada en düşük performansı gösteren LR ve en yüksek performansı gösteren RF modellerinin karmaşıklık matrisleri karşılaştırılmıştır.

LR modelinin analiz sonuçları (Şekil 5) incelendiğinde, modelin test veri setindeki 102 adet gerçek arızadan sadece 14 tanesini doğru tespit edebildiği görülmektedir. Geriye kalan 88 arızalı durum, model tarafından yanlışlıkla "Çalışır" olarak sınıflandırılmış ve gözden kaçırılmıştır. Bu durum, LR'ın Recall skorunun 0,14 gibi endüstriyel açıdan yetersiz bir seviyede kalmasına neden olmuştur. Bu başarısızlığın temel nedeni, sensör verileri ile arıza durumu arasındaki ilişkinin doğrusal (linear) olmaması ve basit doğrusal modellerin bu karmaşık ve çok boyutlu arıza örüntülerini öğrenmede yetersiz kalmasıdır.



Şekil 5. Lojistik Regresyon modelinin karmaşıklık matrisi ve düşük arıza tespit oranı.


Buna karşın, topluluk öğrenme temelli RF algoritması (Şekil 6), aynı veri seti üzerinde çok daha üstün bir performans sergilemiştir. RF modeli, 102 arızanın 60 tanesini doğru tespit etmeyi başarmış ve arıza yakalama oranını (Recall) 0,59'a yükseltmiştir. Ayrıca F1-Score 0,70 seviyesine ulaşmıştır. Diğer algoritmalarla kıyaslandığında (SVM Recall: 0,20), RF algoritması arızaları tespit etmede en az 3 kat daha başarılı olmuştur. Bu sonuç, "Bagging" yöntemiyle birden fazla karar ağacını birleştiren yapının, dengesiz veri setlerinde azınlık sınıfını (arızayı) tespit etmede tekil modellere göre çok daha kararlı ve güvenilir olduğunu kanıtlamaktadır.



Şekil 6. Rastgele Orman modelinin karmaşıklık matrisi ve performans metrikleri.

ROC-AUC Eğrisi ile Model Kararlılığı

Modellerin sınıflandırma eşik değerinden bağımsız olarak "Çalışır" ve "Arızalı" sınıflarını birbirinden ne kadar iyi ayırdığını gösteren **ROC** eğrileri Şekil 7'de sunulmuştur. **AUC** değerinin 1'e yakın olması, modelin mükemmel ayırım yaptığını gösterir.



Şekil 7. Modellerin ROC eğrileri ve AUC skorlarının karşılaştırılması.

Şekil 7'den görüldüğü üzere, RF (AUC = 0,97) ve SVM (AUC = 0,94), LR'a (AUC = 0,88) göre çok daha kararlı bir performans sergilemiştir. Özellikle RF eğrisinin sol üst köşeye en yakın olması, bu modelin yanlış alarm oranını (False Positive - FP) düşük tutarken, arıza yakalama oranını (True Positive - TP) maksimize ettiğini (yüksek ayırt etme gücü) kanıtlamaktadır.

Tartışma

Elde edilen deneysel bulgular, endüstriyel bakım verilerinin analizinde algoritma seçiminin kritik bir rol oynadığını açıkça ortaya koymaktadır. İlk olarak, doğrusal modellerin yetersizliği gözlemlenmiştir. LR modelinin %97 gibi yüksek bir Accuracy oranına ulaşmasına rağmen arıza tespitinde (Recall: 0,14) başarısız olması, endüstriyel sensör verilerinin doğrusal olmayan (non-linear) ve karmaşık bir yapıya sahip olduğunu göstermektedir. Basit doğrusal modeller, bu karmaşık arıza örüntülerini öğrenmede sınırlı kalmaktadır.

Öte yandan, topluluk öğrenme yöntemlerinin gücü deneysel olarak doğrulanmıştır. RF algoritması, tekil DT modeline göre hem AUC (0,97'ye karşı 0,93) hem de F1-Score açısından daha başarılı sonuçlar üretmiştir. Bu bulgu, literatürde Breiman [8] ve Chaleshtori [9] tarafından da belirtildiği üzere, "Bagging" yönteminin varyansı düşürerek modelin genelleme yeteneğini artırdığını ve özellikle gürültülü endüstriyel verilerde daha kararlı bir yapı sunduğunu desteklemektedir.

Analizlerde dikkat çeken bir diğer önemli husus, dengesiz veri etkisidir. Tüm modellerde Recall değerlerinin Precision değerlerinden daha düşük seyretmesi, veri setindeki ciddi sınıf dengesizliğinin ("Sağlam" sınıfının baskınlığı) algoritmaları istatistiksel olarak hata payını düşürmek adına "güvenli tarafta kalmaya" ve çoğunluk sınıfını tahmin etmeye yönelttiğini göstermektedir. Bu kısıtın aşılması için gelecek çalışmalarda SMOTE gibi sentetik veri çoğaltma tekniklerinin veya maliyet duyarlı öğrenme (cost-sensitive learning) yaklaşımlarının kullanılması, arıza yakalama performansını daha da artırabilir.

Sonuç olarak, Endüstri 4.0 tabanlı PdM uygulamalarında model başarısının sadece Accuracy metriği ile ölçülmemesi gerektiği; karmaşık ve çok boyutlu sensör verilerinin modellenmesinde ise RF gibi topluluk öğrenme yaklaşımlarının en uygun aday olduğu deneysel olarak kanıtlanmıştır.

REFERANSLAR

- [1] H. Lasi, P. Fettke, H. G. Kemper, T. Feld, and M. Hoffmann, "Industry 4.0," *Business & Information Systems Engineering*, vol. 6, no. 4, pp. 239–242, 2014.
- [2] T. P. Carvalho, F. A. A. M. N. Soares, R. Vita, R. d. P. Francisco, J. P. Basto, and S. G. S. Alcalá, "A systematic literature review of machine learning methods applied to predictive maintenance," *Computers & Industrial Engineering*, vol. 137, Art. no. 106024, 2019.
- [3] Senseye (A Siemens Company), *The True Cost of Downtime 2022*, Senseye, UK, White Paper, 2022.
- [4] G. A. Susto, A. Schirru, S. Pampuri, S. McLoone, and A. Beghi, "Machine learning for predictive maintenance: A multiple classifier approach," *IEEE Transactions on Industrial Informatics*, vol. 11, no. 3, pp. 812–820, 2015.
- [5] S. Matzka, "Explainable Artificial Intelligence for Predictive Maintenance Applications," in *2020 Third International Conference on Artificial Intelligence for Industries (AI4I)*, Irvine, CA, USA, 2020, pp. 69–74.
- [6] R. Teti, K. Jemielniak, G. O'Donnell, and D. Dornfeld, "Advanced monitoring of machining operations," *CIRP Annals - Manufacturing Technology*, vol. 59, no. 2, pp. 717–739, 2010.
- [7] Y. Mahale, S. Kolhar, and A. S. More, "A comprehensive review on artificial intelligence driven predictive maintenance in vehicles: technologies, challenges and future research directions," *Discover Applied Sciences*, vol. 7, no. 4, Art. no. 243, 2025.
- [8] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [9] M. Chaleshtori and A. Aghaie, "Reliability assessment and maintenance optimization of production systems using Random Forests," *International Journal of Quality & Reliability Management*, vol. 40, no. 1, pp. 90–112, 2023.
- [10] R. Zhao, R. Yan, Z. Chen, K. Mao, P. Wang, and R. X. Gao, "Deep learning and its applications to machine health monitoring," *Mechanical Systems and Signal Processing*, vol. 115, pp. 213–237, 2019.
- [11] M. Rizzi, M. Russo, and M. L. Corradini, "Cost-sensitive fault identification in predictive maintenance applications: a Case Study," in *2021 IEEE International Workshop on Metrology for Industry 4.0 & IoT (MetroInd4.0&IoT)*, Rome, Italy, 2021, pp. 48–53.
- [12] S. Kaufman, S. Rosset, C. Perlich, and O. Stitelman, "Leakage in data mining: Formulation, detection, and avoidance," *ACM Transactions on Knowledge Discovery from Data*, vol. 6, no. 4, Art. no. 15, Dec. 2012.
- [13] D. G. Kleinbaum and M. Klein, *Logistic Regression: A Self-Learning Text*, 3rd ed. New York, NY, USA: Springer, 2010.
- [14] C. Cortes and V. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.
- [15] J. R. Quinlan, "Induction of decision trees," *Machine Learning*, vol. 1, no. 1, pp. 81–106, 1986.