



T. C.
SELÇUK ÜNİVERSİTESİ
TEKNOLOJİ FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

VERİ MADENCİLİĞİ DERSİ

Demir (FE) Atomik Spektrum
VERİSİ

233301076 – Mahmut Esat KOLAY

Doç. Dr. Murat KÖKLÜ

25 Aralık 2025 veya 16 Ocak 2025

İÇİNDEKİLER

1. ÖZET	3
2. ÖDEVDE KULLANACAĞINIZ PROGRAMIN ANLATIMI.....	4
3. SINIFLANDIRMA ALGORİTMALARI.....	5
3.1. Naive Bayes Algoritması.....	5
3.2. Random Forest Algoritması	5
3.3. Destek Vektör Makineleri Algoritması	5
4. MATERYAL VE YÖNTEM.....	5
4.1. Verinin Elde Edilmesi	6
4.2. Verinin Özellikleri	7
4.3. Performans Ölçümleri	9
4.4. Çapraz Doğrulama	10
5. ARAŞTIRMA SONUÇLARI VE TARTIŞMA	12
5.1. Naive bayes Algoritması Sonuçları	12
5.2. Random Forest Algoritması Sonuçları.....	13
5.3. Destek Vektör Makineleri Algoritması Sonuçları	14
6. SONUÇLAR	16
7. ÖNERİLER	18
8. KAYNAKLAR.....	19

1. ÖZET

Bu çalışmada, makine öğrenmesi algoritmaları kullanılarak demir (Fe) elementinin atomik spektral verileri üzerinden iyonlaşma durumlarının sınıflandırılması gerçekleştirilmiştir. Veri seti, Ulusal Standartlar ve Teknoloji Enstitüsü (NIST) Atomik Spektrum Veritabanı'ndan (ASD) elde edilmiş olup [1]; dalga boyu, bağlı yoğunluk, geçiş olasılığı (A_{ki}) ve enerji seviyeleri (E_i , E_k) özelliklerini içermektedir. Çalışmanın temel amacı, veri setinde baskın olan "Singly Ionized" (Fe II) ve "Doubly Ionized" (Fe III) sınıflarını yüksek doğrulukla ayırt edebilen en etkin modeli belirlemektir.

Metodoloji kapsamında; veri ön işleme, eksik verilerin temizlenmesi, "Enerji Farkı (ΔE)" özneteliğinin türetilmesi ve verilerin standartlaştırılması (Standard Scaling) adımları Python Scikit-Learn kütüphanesi kullanılarak gerçekleştirilmiştir [2]. Sınıflandırma aşamasında literatürde yaygın olarak kullanılan Naive Bayes [5], Random Forest [3] ve Destek Vektör Makineleri (SVM) [4] algoritmaları tercih edilmiş; modellerin güvenilirliği 10-Katlı Çapraz Doğrulama (10-Fold Cross Validation) yöntemi ile test edilmiştir.

Analiz sonuçlarına göre; Random Forest algoritması, veri setindeki karmaşık ve doğrusal olmayan ilişkileri modellemedeki başarısı sayesinde %99.15 F1-Skoru ve %99.16 Doğruluk (Accuracy) oranı ile en yüksek performansı sergilemiştir. Bunu %97.73 başarı oranıyla SVM takip ederken, Naive Bayes algoritması %89.94 seviyesinde kalmıştır. Bu çalışma, atomik fizik verilerinin yapay zeka ile analizinde topluluk öğrenme (ensemble learning) yöntemlerinin üstünlüğünü kanıtlamaktadır.

2. ÖDEVDE KULLANACAĞINIZ PROGRAMIN ANLATIMI

Bu çalışmada, veri madenciliği süreçlerinin veri hazırlığından model değerlendirmesine kadar olan tüm aşamalarını gerçekleştirmek amacıyla **Python** programlama dili tercih edilmiştir. Python; nesne yönelimli, yorumlanabilir, modüler ve yüksek seviyeli bir programlama dili olup, özellikle veri bilimi ve yapay zeka uygulamalarında sağladığı geniş kütüphane desteği ile literatürde standart haline gelmiştir [6]. Açık kaynak kodlu yapısı, platform bağımsız çalışabilmesi ve geniş geliştirici topluluğu sayesinde, karmaşık veri analizlerinde esneklik ve hız avantajı sağlamaktadır [7].

Çalışma kapsamında kullanılan temel Python kütüphaneleri ve işlevleri aşağıda özetlenmiştir:

- **Pandas:** Yüksek performanslı veri yapıları ve veri analiz araçları sunan bir kütüphanedir. Bu projede, NIST veritabanından çekilen ham verilerin DataFrame formatında tutulması, eksik verilerin yönetilmesi ve öznitelik mühendisliği (Feature Engineering) işlemleri için kullanılmıştır [8].
- **Scikit-Learn (sklearn):** Python ekosistemindeki en kapsamlı makine öğrenmesi kütüphanesidir. Veri ön işleme (StandardScaler, LabelEncoder), sınıflandırma algoritmalarının (Naive Bayes, Random Forest, SVM) uygulanması ve model performansının 10-Katlı Çapraz Doğrulama ile test edilmesi süreçleri bu kütüphane ile yürütülmüştür [2].
- **Matplotlib ve Seaborn:** Veri görselleştirme kütüphaneleridir. Elde edilen sayısal sonuçların, karmaşıklık matrislerinin (Heatmap) ve karşılaştırmalı performans grafiklerinin yayın kalitesinde görselleştirilmesinde kullanılmıştır [9].

Python'un sunduğu bu entegre geliştirme ortamı, ham verinin anlamlı bilgiye dönüştürülmesi sürecinde (KDD - Knowledge Discovery in Databases) bütüncül ve verimli bir çalışma alanı sağlamıştır.

3. SINIFLANDIRMA ALGORİTMALARI

Sınıflandırma, veri madenciliğinde nesnelerin veya veri örneklerinin özelliklerine (niteliklerine) dayalı olarak, önceden tanımlanmış sınıf etiketlerinden birine atanması işlemidir. Denetimli öğrenme (supervised learning) kategorisinde yer alan bu yöntem, geçmiş verilerden öğrenerek gelecekteki veya bilinmeyen verilerin hangi sınıfa ait olacağını tahmin etmek amacıyla kullanılır [10]. Bu çalışmada, NIST spektral verilerini sınıflandırmak amacıyla **Python** kütüphaneleri kullanılarak **Naive Bayes**, **Random Forest** ve **Destek Vektör Makineleri (SVM)** algoritmaları ile modelleme yapılmıştır.

3.1. Naive Bayes (Gaussian)

Naive Bayes, istatistiksel temellere dayanan ve köklerini Bayes Teoremi'nden alan olasılıksal bir sınıflandırma yöntemidir. Algoritmanın "Naive" (saf/basit) olarak nitelendirilmesinin sebebi, veri setindeki her bir özelliğin (feature) sınıf oluşumuna etkisinin, diğer özelliklerden tamamen bağımsız olduğunu varsaymasıdır [5]. Bu varsayım gerçek hayatta her zaman tam olarak sağlanamasa da, algoritmanın hesaplama maliyetinin çok düşük olması ve yüksek boyutlu verilerde hızlı sonuçlar üretmesi onu popüler bir tercih haline getirmiştir. Bu çalışmada, özneliklerin sürekli sayısal değerler içermesi nedeniyle, verilerin normal dağılıma uyduğunu varsayan **Gaussian Naive Bayes** varyasyonu kullanılmıştır.

3.2. Random Forest

Random Forest, makine öğrenmesinde "topluluk öğrenme" (ensemble learning) olarak bilinen yaklaşımı kullanan güçlü bir algoritmadır. Temel çalışma prensibi, eğitim verisinden rastgele örneklemeler alarak (bagging yöntemi) birbirinden bağımsız çok sayıda karar ağacı (decision tree) oluşturmaktır. Sınıflandırma işlemi yapılırken, oluşturulan tüm ağaçların tahminleri alınır ve "çoğunluk oylaması" (majority voting) yapılarak nihai sonuca ulaşılır [3]. Tek bir karar ağacının veriyi ezberleme (overfitting) riskine karşı, Random Forest çoklu ağaç yapısı sayesinde hatayı minimize eder ve gürültülü verilerde dahi yüksek genelleme başarısı sağlar.

3.3. Destek Vektör Makineleri

Destek Vektör Makineleri (SVM), verileri farklı sınıflara ayırmak için uzayda en ideal sınır çizgisini veya hiperdüzlemi (hyperplane) bulmayı hedefleyen bir algoritmadır. SVM'in temel amacı, sınıflara ait en yakın veri noktaları (destek vektörleri) arasındaki mesafeyi, yani "marjini" maksimize ederek en güvenli ayrımı yapmaktır [4]. Verilerin doğrusal bir çizgiyle ayrılamadığı karmaşık durumlarda, SVM "Çekirdek Hilesi" (Kernel Trick) adı verilen bir matematiksel yöntem kullanır. Bu çalışmada, spektral verilerin karmaşık yapısını çözümlmek için verileri daha yüksek boyutlu bir uzaya taşıyan RBF (Radyal Tabanlı Fonksiyon) çekirdeği tercih edilmiştir.

4. MATERYAL VE YÖNTEM

4.1. Verinin Elde Edilmesi

Bu çalışmada kullanılan veri seti, atomik fizik ve spektroskopi alanında dünyanın en güvenilir referans kaynaklarından biri kabul edilen **ABD Ulusal Standartlar ve Teknoloji Enstitüsü (NIST)** bünyesindeki Atomik Spektrum Veritabanı'ndan (ASD - Atomic Spectra Database) elde edilmiştir [1]. Veri toplama süreci manuel kopyalama yöntemiyle değil, **Python** programlama dili kullanılarak geliştirilen dinamik bir **veri kazıma (web scraping)** algoritması ile otomatikleştirilmiştir. Bu yöntem, verinin güncelliğini korumasını ve insan hatasından arındırılmış olmasını sağlamıştır.

Veri çekme işlemi için Python'un requests kütüphanesi kullanılarak NIST sunucularına, Demir (Fe) elementinin 200 nm ile 1000 nm dalga boyu aralığındaki tüm spektral çizgilerini içeren parametrelerle HTTP istekleri gönderilmiştir. Sunucudan dönen HTML formatındaki ham veri tabloları, pandas kütüphanesi aracılığıyla ayrıştırılarak (parsing) yapısal bir veri çerçevesine (DataFrame) dönüştürülmüştür [8]. İlk aşamada elde edilen ham veri seti yaklaşık 2400 satırdan oluşmaktadır.

Sınıflandırma kurgusu, veri setinde en fazla örnekleme sahip olan ve fiziksel olarak ayırt edilmesi en kritik iki iyonlaşma durumu üzerine inşa edilmiştir. Veri setindeki dengesizliği önlemek ve model başarısını artırmak amacıyla, az sayıda örneği bulunan nötr demir (Fe I) verileri yerine, veri setinin çoğunluğunu oluşturan **Fe II (Singly Ionized / Tek İyonize)** ve **Fe III (Doubly Ionized / Çift İyonize)** sınıfları hedef değişken olarak seçilmiştir.

Verinin modele hazır hale getirilmesi sürecinde sırasıyla şu aşamalar gerçekleştirilmiştir:

1. **Veri Kazıma (Data Scraping):** NIST veritabanına bağlanılarak Fe elementine ait ham spektral veriler çekilmiş ve nist_fe_all_raw.csv dosyasına kaydedilmiştir.
2. **Öznitelik Seçimi (Feature Selection):** Modelin başarısı için kritik öneme sahip olan Dalga Boyu (Wavelength), Bağlı Yoğunluk (Intensity), Geçiş Olasılığı (A_{ki}) ve Enerji Seviyeleri (E_i , E_k) sütunları seçilmiştir.
3. **Veri Temizleme (Data Cleaning):** Ham veri içerisinde bulunan ve sayısal analizi engelleyen fiziksel notasyonlar (örneğin belirsizlik ifade eden *, h, [gibi karakterler), Düzenli İfadeler (Regular Expressions - Regex) kullanılarak temizlenmiş ve tüm veriler ondalıklı sayı (float) formatına dönüştürülmüştür.
4. **Sınıf Filtreleme:** Hedeflenen ikili sınıflandırma problemi için veri seti filtrelenmiş, sadece "**Singly Ionized**" (**Fe II**) ve "**Doubly Ionized**" (**Fe III**) etiketine sahip satırlar ayrıştırılmıştır.
5. **Öznitelik Mühendisliği (Feature Engineering):** Mevcut özelliklere ek olarak, atomun fiziksel durumunu daha iyi temsil etmesi amacıyla Üst Enerji ve Alt Enerji arasındaki farkı gösteren " **ΔE** " adında yeni bir öznitelik türetilmiştir.

4.2. Verinin Özellikleri

Veri madenciliği sürecinin en kritik aşaması, ham verinin (raw data) modelin anlayabileceği temiz ve yapısal bir formata dönüştürülmesidir. Bu çalışmada kullanılan veri seti, başlangıçta NIST veritabanından çekilen karmaşık ve gürültülü bir yapıya sahipken, bir dizi ön işleme adımı sonucunda makine öğrenmesi için optimize edilmiştir.

4.2.1. Ham Veri Setinin Yapısı (Raw Data)

Veri kazıma işlemi sonucunda elde edilen ham veri seti, fiziksel ölçüm notlarını ve metin tabanlı açıklamaları içeren toplam **12 farklı özniteliğe** sahiptir. Ham veri setinde yer alan sütunlar ve içerikleri şöyledir:

1. **Observed Wavelength (Gözlemlenen Dalga Boyu):** Spektral çizginin ölçülen dalga boyudur. Ancak ham veride bazı değerlerin yanında ölçüm hassasiyetini belirten *, h gibi semboller bulunmaktadır (Örn: 245.3*).
2. **Ritz Wavelength:** Teorik olarak hesaplanan dalga boyudur.
3. **Rel. Int. (Bağıl Yoğunluk):** Çizginin parlaklığıdır. Ancak bu sütun yoğun miktarda ölçüm notu içermektedir (Örn: 1000*, bl, h). Ayrıca bazı satırlar tamamen boştur.
4. **Aki (Geçiş Olasılığı):** Einstein katsayısı olarak bilinir. Birçok satırda eksik veri (NaN) bulunmaktadır.
5. **Acc (Doğruluk):** Verinin güvenilirliğini gösteren kategorik harflerdir (A, B, C, D, E). Sayısal bir karşılığı olmadığı için modelde doğrudan kullanılamaz.
6. **Ei (Alt Enerji):** Enerji seviyesini gösterir ancak [123.4] gibi parantezli (tahmini) değerler içerebilmektedir.
7. **Ek (Üst Enerji):** Üst enerji seviyesidir. Ei ile benzer gürültülere sahiptir.
8. **Lower Level Conf.:** Elektron konfigürasyonu (Örn: 3d6.4s). Metin (string) tabanlıdır.
9. **Upper Level Conf.:** Üst seviye elektron dizilimidir. Metin tabanlıdır.
10. **Term:** Kuantum terim sembolleri. Metin tabanlıdır.
11. **J:** Açısal momentum kuantum sayısı. Kesirli ifadeler (1/2, 3/2) içerdiği için doğrudan işlenemez.
12. **Type:** Geçiş türü (Örn: M1, E2).

4.2.2. Veri Ön İşleme ve Dönüşüm Adımları

Ham veri seti üzerinde, gürültüyü azaltmak ve model performansını artırmak amacıyla şu dönüşümler uygulanmıştır:

- **Öznitelik Seçimi (Feature Selection):** Modelin öğrenme sürecine katkısı olmayan metin tabanlı sütunlar (*Conf*, *Term*, *J*, *Type*) ve çok fazla eksik veri barındıran veya kategorik olan sütunlar (*Acc*, *Ritz*) veri setinden çıkarılmıştır.
- **Regex ile Temizleme:** Sayısal sütunlarda (*Wavelength*, *Intensity*, *E_i*, *E_k*) bulunan harf ve özel karakterler (*, [,], h) Düzenli İfadeler (Regex) kullanılarak temizlenmiş, veriler saf sayısal (float64) formata dönüştürülmüştür.
- **Eksik Veri Tamamlama (Imputation):** Aki sütunundaki eksik değerler, veri dağılımını bozmamak adına sütunun **medyan (ortanca)** değeri ile doldurulmuştur.
- **Sınıf Filtreleme:** Veri setindeki dengesizliği gidermek adına, sadece en çok veriye sahip olan **Fe II** ve **Fe III** sınıfları analiz için seçilmiştir.

4.2.3. Model İçin Seçilen ve Türetilen Öznitelikler

Yapılan temizlik işlemlerinin ardından model eğitiminde kullanılmak üzere **6 adet sayısal öznitelik** belirlenmiştir:

- **Özellik 1 (Wavelength):** Nanometre (nm) cinsinden dalga boyu. (Dönüşüm: String -> Float)
- **Özellik 2 (Intensity):** Spektral çizginin parlaklığı. (Dönüşüm: String -> Float)
- **Özellik 3 (Aki):** Geçiş olasılığı. (Dönüşüm: Eksik veriler medyan ile dolduruldu)
- **Özellik 4 (E_i):** Alt enerji seviyesi (cm^{-1}). (Dönüşüm: Parantezler temizlendi -> Float)
- **Özellik 5 (E_k):** Üst enerji seviyesi (cm^{-1}). (Dönüşüm: Parantezler temizlendi -> Float)
- **Özellik 6 (Delta_E): [Öznitelik Mühendisliği]** Ham veride bulunmayan, fiziksel ayırt ediciliği artırmak için tarafımızca türetilen özelliktir. Üst ve alt enerji farkını temsil eder ($\Delta E = E_k - E_i$).
- **Class (Ion):** Hedef değişkendir.
 - **0:** Singly Ionized (Fe II)
 - **1:** Doubly Ionized (Fe III)
 - (Dönüşüm: Label Encoding işlemi ile "Fe II" -> 0 ve "Fe III" -> 1 olarak sayısallaştırılmıştır.)

Tüm bu işlemlerin sonunda, modelin mesafeye duyarlı algoritmalarla (özellikle SVM) daha iyi çalışabilmesi için 6 giriş özelliği **Standard Scaler** yöntemiyle ölçeklendirilmiştir [2].

4.3. Performans Ölçümleri

Sınıflandırma problemlerinde oluşturulan modellerin başarısını değerlendirmek, sadece doğru tahmin sayısına bakmaktan daha kapsamlı bir analiz gerektirir. Modelin hangi sınıfta ne kadar hata yaptığını, pozitif ve negatif örnekleri ayırt etme gücünü anlamak için istatistiksel metrikler kullanılır. Bu çalışmada, model performansını değerlendirmek için temel olarak **Karmaşıklık Matrisi (Confusion Matrix)** ve bu matristen türetilen **Accuracy, Precision, Recall** ve **F1-Skor** metrikleri kullanılmıştır.

4.3.1. Karmaşıklık Matrisi (Confusion Matrix)

Karmaşıklık matrisi, bir sınıflandırma modelinin gerçek değerler ile tahmin edilen değerleri arasındaki ilişkiyi gösteren 2×2 boyutunda bir tablodur. Matris, modelin yaptığı doğru ve yanlış tahminleri dört temel bileşen üzerinden özetler:

- **Doğru Pozitif (TP - True Positive):** Modelin "Doubly Ionized" (1) olarak tahmin ettiği ve gerçekte de "Doubly Ionized" olan örneklerdir.
- **Doğru Negatif (TN - True Negative):** Modelin "Singly Ionized" (0) olarak tahmin ettiği ve gerçekte de "Singly Ionized" olan örneklerdir.
- **Yanlış Pozitif (FP - False Positive):** Modelin "Doubly Ionized" tahmin ettiği ancak gerçekte "Singly Ionized" olan örneklerdir (Tip-1 Hata).
- **Yanlış Negatif (FN - False Negative):** Modelin "Singly Ionized" tahmin ettiği ancak gerçekte "Doubly Ionized" olan örneklerdir (Tip-2 Hata).

4.3.2. İki Sınıflı Performans Metrikleri

Karmaşıklık matrisinden elde edilen TP, TN, FP ve FN değerleri kullanılarak aşağıdaki başarı kriterleri hesaplanmıştır:

1. Doğruluk (Accuracy - %):

Modelin toplam veri seti içerisinde ne kadar doğru tahmin yaptığını gösteren en genel metriktir. Hem pozitif hem de negatif sınıfların doğru tahmin edilme oranını verir.

$$Accuracy = \frac{Toplam\ Doğru\ Tahmin\ Sayısı}{Toplam\ Veri\ Sayısı}$$

2. Kesinlik (Precision - %):

Modelin "Pozitif" (Doubly Ionized) olarak tahmin ettiği verilerin ne kadarının gerçekten pozitif olduğunu gösterir. Yanlış pozitif hatalarının (FP) maliyetinin yüksek olduğu durumlarda kritik öneme sahiptir.

$$Precision_k = \frac{TP_k}{TP_k + FP_k}$$

3. Duyarlılık (Recall - %):

Gerçekten "Pozitif" olan örneklerin ne kadarının model tarafından doğru yakalandığını ifade eder. Modelin gözden kaçırdığı pozitif örnekleri (FN) minimize etmeyi amaçlar.

$$Recall_k = \frac{TP_k}{TP_k + FN_k}$$

4. F1-Skor (%):

Kesinlik (Precision) ve Duyarlılık (Recall) değerlerinin harmonik ortalamasıdır. Özellikle veri setinde sınıf dengesizliği olduğu durumlarda veya hem yanlış pozitiflerin hem de yanlış negatiflerin önemli olduğu durumlarda, Accuracy değerinden daha güvenilir bir başarı ölçütüdür.

$$F1_{score_k} = 2 \times \frac{Precision_k \times Recall_k}{Precision_k + Recall_k}$$


4.4. Çapraz Doğrulama

Makine öğrenmesi modellerinin başarısını değerlendirirken, veriyi sadece tek bir kez "Eğitim" ve "Test" olarak ayırmak (hold-out yöntemi), verinin dağılımına bağlı olarak yanıltıcı sonuçlar doğurabilir. Modelin veriyi ezberlemesini (overfitting) engellemek ve görmediği veriler üzerindeki genelleme yeteneğini en doğru şekilde ölçmek amacıyla, bu çalışmada **k-Katlı Çapraz Doğrulama (k-Fold Cross Validation)** yöntemi uygulanmıştır.

Çapraz doğrulama sürecinin işleyişi şu şekildedir:

1. Veri seti rastgele karıştırılır ve **k** adet eşit parçaya (fold) bölünür.
2. Her iterasyonda, parçalardan bir tanesi "**Test Seti**" olarak ayrılırken, geriye kalan $k-1$ adet parça "**Eğitim Seti**" olarak birleştirilir.
3. Model eğitilir ve ayrılan test seti üzerinde performansı ölçülür.
4. Bu işlem, her bir parça tam bir kez test seti olacak şekilde k defa tekrarlanır.
5. Son aşamada, elde edilen **k** adet başarı skorunun ortalaması alınarak modelin nihai performans değeri hesaplanır.

Bu çalışmada, modelin güvenilirliğini maksimize etmek ve yanlılığı (bias) minimize etmek amacıyla **k=10** değeri seçilmiştir (10-Fold Cross Validation). Yani veri seti 10 eşit parçaya ayrılmış, algoritmalar 10 kez eğitilip test edilmiş ve elde edilen 10 sonucun ortalaması raporlanmıştır. Bu yöntem, modelin veri setinin sadece belirli bir kısmına değil, tamamına hakim olmasını sağlar.



Şekil 1 [11]: 10K-Fold cross- validation method diagram

- **Veri Bölümleme:** Mevcut veri seti, rastgele dağılım prensibiyle karıştırılarak 10 eşit alt kümeye (fold) ayrıştırılır.
- **İteratif Süreç:** Doğrulama işlemi, 10 ardışık iterasyon (döngü) şeklinde gerçekleştirilir.
- **Eğitim ve Test:** Her bir iterasyonda, alt kümelerden 1 tanesi "Test Seti" olarak validasyon için ayrılırken; geriye kalan 9 alt küme birleştirilerek "Eğitim Seti" (Training Set) oluşturulur ve model bu veri ile eğitilir.
- **Döngü Tamamlanması:** Bu işlem, veri setindeki her bir parçanın tam olarak bir kez test verisi olarak kullanılması sağlanana kadar devam eder.

Sürecin sonunda, 10 farklı test aşamasından elde edilen başarı puanlarının aritmetik ortalaması alınarak modelin nihai performans değeri (Accuracy) hesaplanır. Bu yöntem, verinin belirli bir kısmına dayalı yanlılığı (bias) ortadan kaldırarak modelin aşırı öğrenme (overfitting) riskini minimize eder ve model performansının tarafsız bir şekilde raporlanmasını sağlar.

5. ARAŞTIRMA SONUÇLARI VE TARTIŞMA

5.1. Algoritma_1 Sonuçları

NIST spektral veri seti üzerinde Gaussian Naive Bayes algoritması kullanılarak gerçekleştirilen sınıflandırma işleminde, modelin genel performansı 10-Katlı Çapraz Doğrulama (10-Fold Cross Validation) yöntemi ile test edilmiştir. Algoritmadan elde edilen kümülatif sonuçlar incelendiğinde, toplam veri setindeki örneklerin büyük çoğunluğunun doğru sınıflandırıldığı, ancak sınıflar arası ayırt etme başarısının dengesiz olduğu gözlemlenmiştir.

Tablo 5.1’de Naive Bayes algoritmasına ait karmaşıklık matrisi verilmiştir. Bu matris incelendiğinde; modelin "Singly Ionized" (Fe II) sınıfını tanımada oldukça başarılı olduğu ve 1110 adet örneği doğru tahmin ederken sadece 23 adet örneği yanlış sınıflandırdığı görülmüştür. Ancak "Doubly Ionized" (Fe III) sınıfı için yapılan tahminlerde hata oranı artmış; gerçekte Doubly Ionized olan 408 veriden 132 tanesi model tarafından yanlışlıkla "Singly Ionized" olarak tahmin edilmiştir. Bu durum, Naive Bayes algoritmasının, veri setindeki baskın sınıfı (Fe II) seçme eğiliminde olduğunu göstermektedir.

Tablo 5.1. Naive Bayes algoritması karmaşıklık matrisi

Naive Bayes (10-Fold CV) - Karmaşıklık Matrisi		
Gerçek Sınıf	Singly Ionized	Doubly Ionized
	Singly Ionized	Doubly Ionized
Singly Ionized	1110	23
Doubly Ionized	132	276

Algoritmanın sayısal başarı ölçütleri Tablo 5.2’de özetlenmiştir. Tablo incelendiğinde, Naive Bayes modelinin genel **Doğruluk (Accuracy)** oranının **%89.94** olduğu görülmektedir. **Kesinlik (Precision)** değeri **%90.15** olarak hesaplanırken, modelin hatalı negatif tahminlerinden (False Negatives) etkilenen **F1-Skoru %89.40** seviyesinde kalmıştır. Bu sonuçlar, Naive Bayes’in hızlı ve etkili bir başlangıç modeli olduğunu, ancak spektral verilerdeki karmaşık ve doğrusal olmayan ilişkileri (özellikle Doubly Ionized sınıfı için) tam olarak yakalamakta zorlandığını ortaya koymaktadır.

Tablo 5.2. Naive Bayes algoritması performans sonuçları

Metrik	Değer (Ortalama)
Accuracy (Doğruluk)	%89.94
Precision (Kesinlik)	%90.15
Recall (Duyarlılık)	%89.94
F1 Score	%89.40

5.2. Random Forest Sonuçları

Çalışmanın ikinci aşamasında, topluluk öğrenme (ensemble learning) temelli **Random Forest** algoritması kullanılmıştır. 100 adet karar ağacının oluşturduğu bu model, spektral verilerin karmaşık yapısını çözümlemede üstün bir başarı sergilemiştir. **10-Katlı Çapraz Doğrulama** sonuçları, Random Forest'ın hem "Singly Ionized" hem de "Doubly Ionized" sınıflarını ayırt etmede çok yüksek bir genelleme yeteneğine sahip olduğunu göstermektedir.

Tablo 5.3'te sunulan karmaşıklık matrisi incelendiğinde, modelin kararlılığı net bir şekilde görülmektedir. Toplam **1541** adet test verisi içerisinde sadece **13** adet hatalı tahmin yapılmıştır. Model, "**Singly Ionized**" (**Fe II**) sınıfındaki **1133** veriden **1129** tanesini doğru tahmin ederken, sadece **4** tanesini yanlış sınıflandırmıştır. Benzer şekilde, "**Doubly Ionized**" (**Fe III**) sınıfında da başarı oranı çok yüksektir; **408** veriden **399** tanesi doğru bilinmiş, sadece **9** veri kaçırılmıştır. Naive Bayes algoritmasındaki (132 hata) dengesizliğin aksine, Random Forest her iki sınıfta da dengeli ve yüksek performans göstermiştir.

Tablo 5.3. Random Forest algoritması karmaşıklık matrisi

Random Forest (10-Fold CV) - Karmaşıklık Matrisi	
Gerçek Sınıf	Tahmin Edilen
Singly Ionized -	1129 4
Doubly Ionized -	9 399
	Singly Ionized Doubly Ionized

Tablo 5.4. Random Forest algoritması performans sonuçları


Metrik	Değer (Ortalama)
Accuracy (Doğruluk)	%99.16
Precision (Kesinlik)	%99.16
Recall (Duyarlılık)	%99.16
F1 Score	%99.15

Algoritmanın performans metrikleri Tablo 5.4'te verilmiştir. Random Forest modeli, **%99.16** gibi çok yüksek bir **Doğruluk (Accuracy)** oranına ulaşmıştır. **Kesinlik (Precision)** ve **Duyarlılık (Recall)** değerlerinin de **%99.16** olması, modelin yanlılık (bias) içermediğini ve her iki sınıfı da eşit başarıyla tanıdığını kanıtlamaktadır. **%99.15** seviyesindeki **F1-Skoru**, bu modelin fiziksel verileri sınıflandırmada en güvenilir yöntem olduğunu istatistiksel olarak doğrulamaktadır.

5.3. Destek Vektör Makineleri Sonuçları

Sınıflandırma analizinin son aşamasında, verilerin yüksek boyutlu uzayda ayrıştırılmasını sağlayan **Destek Vektör Makineleri (SVM)** algoritması kullanılmıştır. Özellikle doğrusal olmayan veri dağılımlarını modellemek için **RBF (Radyal Tabanlı Fonksiyon)** çekirdeği tercih edilmiş ve modelin başarısı **10-Katlı Çapraz Doğrulama** ile test edilmiştir. Elde edilen sonuçlar, SVM'in spektral verileri sınıflandırmada Naive Bayes'ten çok daha üstün, Random Forest ile de yarışabilir düzeyde yüksek bir performansa sahip olduğunu göstermektedir.

Tablo 5.5'te verilen karmaşıklık matrisi incelendiğinde, SVM modelinin toplam **1541** test verisi üzerinde kararlı bir tahmin yürüttüğü görülmektedir. Model, "**Singly Ionized**" (**Fe II**) sınıfına ait **1133** veriden **1119** tanesini doğru tahmin etmiş, sadece **14** tanesini yanlışlıkla diğer sınıfa atamıştır. "**Doubly Ionized**" (**Fe III**) sınıfında ise **408** veriden **387** tanesi doğru bilinmiş, **21** adet veri yanlış sınıflandırılmıştır. Toplamda yapılan **35** adet hatalı tahmin, veri setinin karmaşıklığı göz önüne alındığında oldukça düşük bir orandır.

Tablo 5.5. SVM algoritması karmaşıklık matrisi

Algoritmanın sayısal performans değerleri Tablo 5.6’da sunulmuştur. SVM modeli, **%97.73** gibi oldukça yüksek bir **Doğruluk (Accuracy)** oranına ulaşmıştır. **Kesinlik (Precision)** ve **F1-Skoru** değerlerinin sırasıyla **%97.72** seviyesinde gerçekleşmesi, modelin sınıflar arasında dengeyi koruduğunu ve herhangi bir sınıfa karşı aşırı yanlılık (bias) göstermediğini kanıtlamaktadır. Bu sonuçlar, fiziksel parametrelerin (Dalga boyu, Enerji seviyeleri vb.) SVM tarafından etkin bir şekilde kullanıldığını ortaya koymaktadır.

Tablo 5.6. SVM algoritması performans sonuçları

Metrik	Değer (Ortalama)
Accuracy (Doğruluk)	%97.73
Precision (Kesinlik)	%97.72
Recall (Duyarlılık)	%97.73
F1 Score	%97.72

6. SONUÇLAR

Bu çalışmada, demir (Fe) elementinin NIST veritabanından alınan spektral özelliklerine dayalı olarak iyonlaşma durumlarını (Singly Ionized ve Doubly Ionized) tahmin etmek amacıyla üç farklı makine öğrenmesi algoritması kıyaslanmıştır. Modellerin performansı, 10-Katlı Çapraz Doğrulama yöntemiyle test edilmiş ve elde edilen sonuçlar **Doğruluk (Accuracy)**, **Kesinlik (Precision)**, **Duyarlılık (Recall)** ve **F1-Skor** metrikleri üzerinden değerlendirilmiştir.

Genel bir değerlendirme yapıldığında; topluluk öğrenme (ensemble learning) tabanlı **Random Forest** algoritmasının, veri setindeki örüntüleri öğrenmede en yüksek başarıyı gösterdiği, onu çekirdek tabanlı **SVM** algoritmasının takip ettiği görülmüştür. Olasılıksal **Naive Bayes** algoritması ise kabul edilebilir bir başarı sergilese de diğer iki modelin gerisinde kalmıştır.


Elde edilen performans ölçümleri aşağıda detaylandırılmıştır:

- **Doğruluk (Accuracy):** Tüm veri seti üzerindeki genel başarı oranını ifade eder. En yüksek doğruluk oranına **%99.16** ile **Random Forest** ulaşmıştır. SVM modeli **%97.73** ile ikinci sırada yer alırken, Naive Bayes **%89.94** oranında kalmıştır.
- **Kesinlik (Precision):** Modelin pozitif tahminlerinin güvenilirliğidir. Random Forest **%99.16** kesinlik değeri ile yanlış pozitif (False Positive) hata oranını minimize etmiştir.
- **Duyarlılık (Recall):** Gerçek sınıfları yakalama kapasitesidir. Random Forest **%99.16** duyarlılık ile gözden kaçırılan veri sayısını (False Negative) neredeyse sıfıra indirmiştir.
- **F1-Skor (F1-Measure):** Sınıf dengesizliğine karşı en dirençli metriktir. Random Forest **%99.15** F1-Skoru ile modelin kararlılığını kanıtlamış, SVM ise **%97.72** ile onu takip etmiştir.

Tablo 6.1. Kullanılan tüm algoritmalar için ortalama performans sonuçları

Model	Accuracy	Precision	Recall	F1 Score
Naive Bayes	%89.94	%90.15	%89.94	%89.40
Random Forest	%99.16	%99.16	%99.16	%99.15
SVM	%97.73	%97.72	%97.73	%97.72

Bu tablodan elde edilen verilerle oluşturulan karşılaştırmalı performans grafiği aşağıda sunulmuştur.

Tablo 6.2. Kullanılan tüm algoritmalar için ortalama performans sonuçları

Grafik 6.2'de görüldüğü üzere; turuncu renk ile temsil edilen **Random Forest** ve yeşil renk ile temsil edilen **SVM** algoritmalarının çubukları birbirine oldukça yakın ve maksimum seviyededir. Buna karşın mavi renkli **Naive Bayes** çubukları belirgin şekilde daha düşüktür.

Bu durumun temel nedeni, spektral verilerin (dalga boyu, enerji seviyeleri ve yoğunluk) birbirleriyle karmaşık ve doğrusal olmayan (non-linear) ilişkilere sahip olmasıdır. Naive Bayes, özellikleri birbirinden bağımsız varsaydığı için bu karmaşık ilişkileri modellemekte yetersiz kalmıştır. Öte yandan Random Forest, çok sayıda karar ağacının ortak kararını kullanarak gürültüyü filtrelemiş ve **%99.16** gibi neredeyse kusursuz bir sonuç ortaya koymuştur.

Sonuç olarak; bu veri kümesi için **en yüksek performansı Random Forest**, en düşük performansı ise Naive Bayes algoritması sergilemiştir. Fiziksel ve atomik verilerin sınıflandırılmasında topluluk öğrenme (ensemble) yöntemlerinin en uygun yaklaşım olduğu tespit edilmiştir.

7. ÖNERİLER

Bu çalışmada, NIST spektral verileri kullanılarak demir (Fe) elementinin iyonlaşma durumları makine öğrenmesi algoritmaları ile başarılı bir şekilde sınıflandırılmıştır. Elde edilen deneyimler ve analiz sonuçları doğrultusunda, gelecekte yapılacak benzer çalışmalar için aşağıdaki öneriler sunulmaktadır:

1. **Hiperparametre Optimizasyonu:** Bu çalışmada algoritmalar büyük ölçüde varsayılan (default) parametreler ile kullanılmıştır. Gelecek çalışmalarda, **Grid Search** veya **Random Search** yöntemleri kullanılarak SVM için C ve Gamma değerleri veya Random Forest için ağaç sayısı (n_estimators) optimize edilerek model performansı daha da yukarı çekilebilir.
2. **Derin Öğrenme (Deep Learning) Yaklaşımları:** Veri seti boyutu artırıldığında, geleneksel makine öğrenmesi yöntemleri yerine **Yapay Sinir Ağları (ANN)** veya **Derin Öğrenme** modelleri denenebilir. Özellikle çok katmanlı yapılar, spektral verilerdeki gizli örüntüleri (pattern) yakalamada daha etkili olabilir.
3. **Sınıf Çeşitliliğinin Artırılması:** Mevcut çalışma, veri集中的 dengesizliği yönetmek adına sadece "Singly Ionized" ve "Doubly Ionized" sınıflarına odaklanmıştır. İleriki aşamalarda, **SMOTE** gibi veri çoğaltma teknikleri kullanılarak nötr atom (Fe I) ve daha yüksek iyonlaşma seviyeleri de analize dahil edilebilir. Böylece model, tüm fiziksel spektrumu kapsayan daha genel bir yapıya kavuşturulabilir.
4. **Öznitelik Önem Analizi:** Random Forest algoritmasının sağladığı "Feature Importance" özelliği kullanılarak, sınıflandırma kararında hangi fiziksel özelliğin (Dalga boyu mu, Enerji farkı mı?) daha baskın olduğu analiz edilebilir. Bu, fizik bilimi açısından da anlamlı çıkarımlar sağlayacaktır.
5. **Farklı Elementlerin Karşılaştırılması:** Model sadece Demir (Fe) elementi üzerinde eğitilmiştir. Oluşturulan bu yapı, Bakır (Cu) veya Çinko (Zn) gibi benzer geçiş metallerine de uygulanarak, modelin elementler arası genelleme yeteneği test edilebilir.

8. KAYNAKLAR

- [1] Kramida, A., Ralchenko, Yu., Reader, J., & NIST ASD Team (2023). *NIST Atomic Spectra Database (ver. 5.11)*. National Institute of Standards and Technology, Gaithersburg, MD. Eriřim Adresi: <https://physics.nist.gov/asd>
- [2] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- [3] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.
- [4] Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273-297.
- [5] Rish, I. (2001). An empirical study of the naive Bayes classifier. *IJCAI 2001 Workshop on Empirical Methods in Artificial Intelligence*, 3(22), 41-46..
- [6] Van Rossum, G., & Drake, F. L. (2009). *Python 3 Reference Manual*. Scotts Valley, CA: CreateSpace.
- [7] Raschka, S., & Mirjalili, V. (2019). *Python Machine Learning: Machine Learning and Deep Learning with Python, scikit-learn, and TensorFlow 2* (3rd ed.). Packt Publishing.
- [8] McKinney, W. (2010). Data Structures for Statistical Computing in Python. *Proceedings of the 9th Python in Science Conference*, 51-56.
- [9] Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90-95.
- [10] Han, J., Kamber, M., & Pei, J. (2011). *Data Mining: Concepts and Techniques* (3rd ed.). Morgan Kaufmann.
- [11] Andrade, J. J., Fonseca, L. G., Farage, M., & Marques, G. L. O. (2020). *Prediction of the Performance of Bituminous Mixes Using Adaptive Neuro-Fuzzy Inference Systems*. ResearchGate. <https://www.researchgate.net/publication/343811122>